INFORME TÉCNICO EJECUTIVO FINAL

Proyecto SOLARIS

FrescaMar S.A.S.

Fecha	01/11/2026
Versión	v5.0
Autor	Nicolás Torres Castellanos
Curso	Proyecto de Ciencia de Datos 2
Universidad	Universidad de La Sabana
Período académico	2026-2
Estado del documento	Entrega final - Módulo 5

Repositorio público del proyecto

github.com/torresnicolas004-afk/SOLARIS-FrescaMar

Contenido

Resumen ejecutivo 2
1. Problema de negocio y objetivos 4
1.1 Objetivos del proyecto 4
1.2 Alcance y restricción central 4
2. Datos, preparación y control de leakage 5
2.1 Predictores utilizados y variables excluidas 5
3. Metodología y selección del modelo 6
3.1 Configuración final 6
4. Resultados finales del modelo 7
4.1 Lectura operativa 7
5. Validación, threshold y robustez 8
6. Interpretabilidad: qué está usando SOLARIS 9
6.1 Explicación de un caso individual 9
7. Equidad, sesgos y riesgos de uso 10
8. Dashboard ejecutivo y aplicación operativa 11
9. Impacto, gobernanza y hoja de ruta 12
9.1 Hoja de ruta recomendada 12
10. Conclusiones y limitaciones 13
10.1 Limitaciones principales 13
10.2 Recomendación final 13
Referencias 13

Resumen ejecutivo

FrescaMar S.A.S. necesita anticipar qué clientes presentan mayor riesgo de mora para priorizar revisiones de crédito y cartera antes de ampliar exposición. El Proyecto SOLARIS responde a esta necesidad mediante un sistema de clasificación que transforma información de perfil, capacidad económica, antigüedad, ubicación y score externo en una probabilidad estimada de mora. La solución fue concebida como apoyo a la decisión y no como un mecanismo automático para aprobar, negar o reducir crédito.

El desarrollo partió de 15.000 registros. Para el modelado binario se excluyeron 2.700 clientes con estado Cancelado y se trabajó con 12.300 observaciones comparables: 10.500 Al día y 1.800 Moroso. Con el fin de reducir riesgo de data leakage, se excluyeron variables cuya temporalidad no podía demostrarse, entre ellas saldo_actual, cuotas_pagadas y cuotas_totales. El modelo final utiliza seis predictores: edad, ingreso_mensual, anio_vinculacion, score_externo, nivel_educativo y ciudad.

Después de comparar una Regresión Logística con HistGradientBoostingClassifier, se seleccionó este último y se optimizó con Optuna mediante 50 trials y validación cruzada estratificada de cinco folds. El AUC-ROC promedio en validación cruzada alcanzó 0,8692, frente a 0,7353 de la línea base. El threshold operativo 0,59 fue seleccionado únicamente con predicciones out-of-fold del conjunto de entrenamiento, preservando el test para la evaluación final.

En los 2.460 casos de test, SOLARIS obtuvo AUC-ROC = 0,8681, precision = 0,4470, recall = 0,7028 y F1 = 0,5464 para la clase Moroso. En términos operativos, detectó 253 de 360 morosos y generó 313 falsas alertas. El gap de AUC entre train y test fue 0,0254, por lo que no se observa evidencia fuerte de sobreajuste en la validación disponible.

La evaluación crítica mostró una limitación relevante: score_externo concentra la mayor señal predictiva y su ausencia altera de forma material el comportamiento del modelo. Los 212 casos de test sin score recibieron alerta con el threshold oficial. Además, se observaron diferencias de desempeño entre subgrupos por educación, ciudad, ingreso y edad. Estos hallazgos no demuestran discriminación causal, pero sí justifican controles de equidad, calidad de datos y revisión humana.

Como producto de cierre se desarrolló un dashboard ejecutivo en Streamlit que integra indicadores, filtros, escenarios de threshold, explicación SHAP, alertas por ausencia de score y una lista descargable de clientes priorizados. El repositorio fue reorganizado, documentado y probado desde un clon limpio con las dependencias declaradas. La recomendación final es avanzar únicamente con un piloto controlado: revisión humana obligatoria, ruta especial para score faltante, monitoreo de desempeño y equidad, trazabilidad de versiones y validación out-of-time antes de cualquier despliegue productivo.

1. Problema de negocio y objetivos

SOLARIS se formuló como un problema de clasificación binaria para apoyar a FrescaMar S.A.S. en la identificación anticipada de clientes con riesgo de mora. El usuario primario es el Director Financiero, acompañado por el equipo de crédito y cartera, quienes necesitan priorizar revisiones y gestionar cupos con criterios comparables entre clientes.

El DDP auditó 15.000 clientes únicos: 10.500 Al día (70%), 2.700 Cancelado (18%) y 1.800 Moroso (12%). La mora es una clase minoritaria, pero financieramente relevante. El DDP estimó un saldo actual promedio cercano a COP 8,68 millones para el grupo Moroso, frente a COP 3,11 millones entre clientes Al día. Esa evidencia justificó construir una señal anticipada de riesgo, pero sin interpretar el saldo observado como pérdida realizada.

Elemento	Definición en SOLARIS
Decisión de negocio	Priorizar revisión de crédito/cartera y apoyar decisiones de cupo.
Información faltante	Probabilidad anticipada y comparable de mora, con explicación y calidad del dato.
Unidad de análisis	Cliente identificado por id_cliente.
Clase positiva	Moroso = 1; Al día = 0.
Usuario principal	Dirección Financiera y equipo de crédito/cartera.

Tabla 1. Traducción del problema de negocio al problema analítico.

1.1 Objetivos del proyecto

- Construir un pipeline reproducible que estime riesgo de mora sin incorporar información con temporalidad dudosa.
- Superar una línea base interpretable y alcanzar AUC-ROC >= 0,75, recall de Moroso cercano o superior a 70% y precision de alertas >= 40%.
- Seleccionar el threshold sin utilizar el conjunto de test y documentar el costo de falsos positivos y falsos negativos.
- Evaluar robustez, interpretabilidad y brechas de desempeño entre subgrupos antes de recomendar un uso operativo.
- Entregar una interfaz ejecutiva que convierta las predicciones en una lista priorizada para revisión humana.

1.2 Alcance y restricción central

El dataset disponible es un snapshot y no contiene fecha_corte ni fecha_evento de mora. Por ello, la evaluación final usa un split IID estratificado y validación cruzada, pero no puede demostrar estabilidad temporal. Una validación out-of-time sigue siendo requisito previo para producción.

2. Datos, preparación y control de leakage

El archivo original SOLARIS_FrescaMar_cartera_credito.csv contiene 15.000 filas y 11 variables. La auditoría inicial encontró integridad estructural adecuada - 15.000 identificadores únicos y sin duplicados -, pero también problemas de calidad: 1.141 faltantes en score_externo, edad igual a 0, ingresos en cero y 73 variantes de escritura en ciudad. Estas observaciones se trataron de manera documentada antes del modelado.

Etapa	Decisión final	Resultado
Población	Excluir estado Cancelado	12.300 registros para clasificación binaria.
Split	80% train / 20% test, estratificado, seed 42	9.840 train y 2.460 test; mora 14,63% en ambos.
Numéricas	Imputación dentro del pipeline; escalamiento cuando aplica	Evita aprendizaje con información del test.
Categóricas	Imputación + OneHotEncoder(handle_unknown="ignore")	Tolerancia a categorías no vistas.
Validación	StratifiedKFold, 5 folds, shuffle=True, seed 42	Comparación y Optuna exclusivamente sobre train.

Tabla 2. Decisiones de preparación y validación.

2.1 Predictores utilizados y variables excluidas

Variable	Decisión	Motivo principal
edad	Incluir	Perfil disponible antes de la decisión; edad = 0 se trata como faltante.
ingreso_mensual	Incluir	Capacidad económica potencialmente previa; ceros se conservan por falta de regla de negocio.
anio_vinculacion	Incluir	Antigüedad derivada de fecha_vinculacion.
score_externo	Incluir con control	Conceptualmente previo, pero con patrón de faltantes relevante.
nivel_educativo / ciudad	Incluir	Perfil categórico; ciudad se normaliza determinísticamente.
saldo_actual	Excluir	Temporalidad no demostrable respecto al estado observado.
cuotas_pagadas / cuotas_totales	Excluir	Pueden reflejar comportamiento posterior o renegociaciones.
id_cliente / estado_cuenta	Excluir	Identificador y variable objetivo.

Tabla 3. Auditoría final de data leakage.

La decisión metodológica más importante fue mantener fuera del modelo variables con señal aparente pero temporalidad dudosa. El objetivo no era maximizar el desempeño retrospectivo, sino construir un prototipo cuyo conjunto de predictores pudiera defenderse como información disponible antes de una decisión crediticia.

3. Metodología y selección del modelo

La estrategia de modelado comparó una Regresión Logística como baseline interpretable con HistGradientBoostingClassifier (HGB) como challenger no lineal. Toda la imputación y codificación se encapsuló en ColumnTransformer + Pipeline, de modo que cada fold aprendiera sus transformaciones solo con los datos de entrenamiento correspondientes.

El HGB se optimizó con Optuna, TPESampler, semilla 42 y 50 trials. Cada trial maximizó AUC-ROC promedio en validación cruzada estratificada de cinco folds sobre train. El conjunto de test permaneció aislado tanto de la comparación de modelos como de la búsqueda de hiperparámetros y de la selección del threshold.

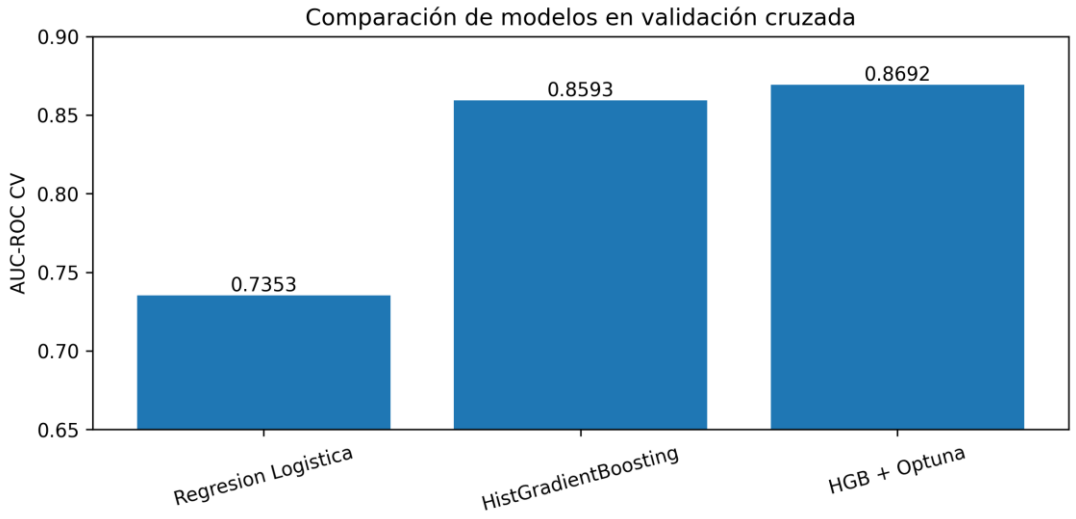


Figura 1. Comparación de modelos mediante AUC-ROC en validación cruzada.

Modelo	AUC CV	Lectura
Regresión Logística	0,7353	Línea base interpretable.
HistGradientBoosting	0,8593	Mejora importante al capturar relaciones no lineales.
HGB + Optuna	0,8692	Modelo final; mejora adicional sin utilizar test.

Tabla 4. Desempeño comparativo de los modelos candidatos.

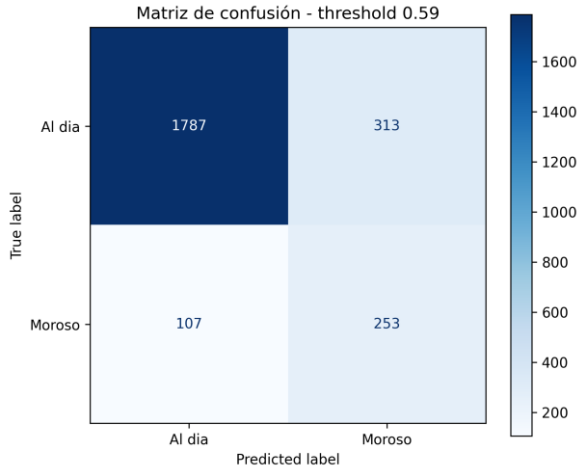
3.1 Configuración final

La optimización seleccionó learning_rate = 0,02113, max_iter = 150, max_leaf_nodes = 15, min_samples_leaf = 26 y l2_regularization = 5,48e-05. El modelo final fue serializado como solaris_hgb_v1_20260915.pkl para asegurar trazabilidad y reutilización.

El threshold operativo se definió después con predicciones out-of-fold de train. Se buscó cumplir simultáneamente precision >= 0,40 y recall >= 0,70; entre los puntos válidos se seleccionó el de mayor F1. El resultado fue 0,59, con precision OOF = 0,4487, recall OOF = 0,7111 y F1 OOF = 0,5502.

4. Resultados finales del modelo

Con el modelo y el threshold congelados antes de observar test, la evaluación final se realizó sobre 2.460 clientes. El AUC-ROC = 0,8681 confirma una buena capacidad para ordenar clientes por riesgo. Para la clase Moroso, precision = 0,4470, recall = 0,7028 y F1 = 0,5464.



Métrica	Resultado
AUC-ROC test	0,8681
Precision Moroso	0,4470
Recall Moroso	0,7028
F1 Moroso	0,5464
AUC train	0,8935
Gap Train-Test	0,0254
Threshold	0,59

Figura 2. Matriz de confusión y métricas finales sobre test.

4.1 Lectura operativa

Resultado	Casos	Interpretación
Verdadero negativo	1.787	Cliente Al día sin alerta.
Falso positivo	313	Cliente Al día enviado innecesariamente a revisión.
Falso negativo	107	Moroso no detectado; principal riesgo financiero.
Verdadero positivo	253	Moroso correctamente priorizado.

Tabla 5. Traducción de la matriz de confusión a decisión de negocio.

SOLARIS identifica 253 de los 360 morosos del conjunto de prueba, es decir, aproximadamente 7 de cada 10. Al mismo tiempo, 313 clientes Al día reciben una alerta. Por esta razón, el resultado es útil para priorizar revisión, pero no tiene precision suficiente para justificar decisiones adversas automáticas.

El gap Train-Test de 0,0254 es bajo frente al control de 0,10 definido en el pipeline. Esto respalda la generalización dentro de la evaluación IID disponible, aunque no reemplaza la validación temporal que requiere un escenario productivo.

5. Validación, threshold y robustez

El threshold representa un compromiso entre capturar morosos y limitar falsas alertas. La sensibilidad evaluada confirma que reducir el punto de corte aumenta recall a costa de precision, mientras que elevarlo hace lo contrario. El valor 0,59 se mantiene como decisión oficial porque fue definido con OOF de train y cumple el criterio previo sin utilizar test para retocarlo.

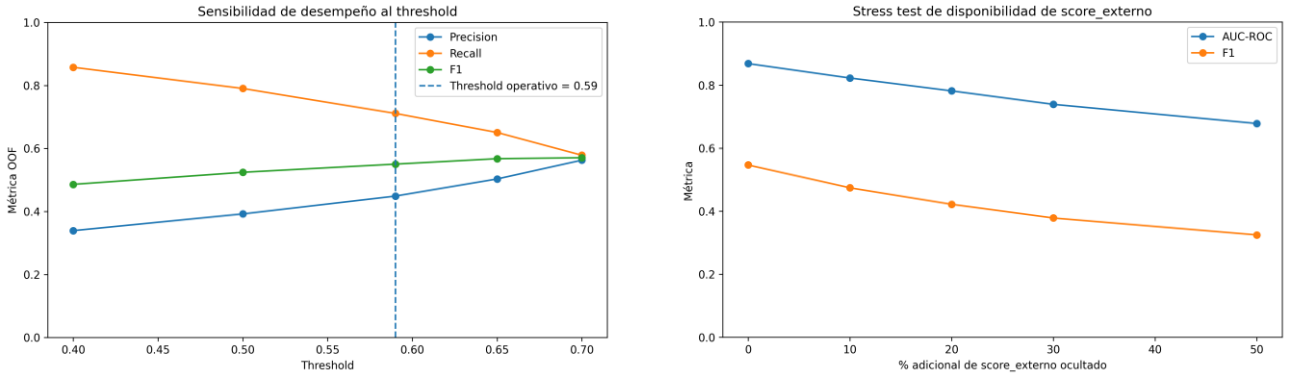


Figura 3. Sensibilidad al threshold (izquierda) y stress test de score_externo faltante (derecha).

Escenario	AUC-ROC	F1	Lectura
Sin faltante adicional	0,8681	0,5464	Referencia del test.
+10% score faltante	0,8223	0,4739	Caída visible de desempeño.
+20% score faltante	0,7815	0,4216	Dependencia material del predictor.
+30% score faltante	0,7387	0,3783	Riesgo alto de degradación.
+50% score faltante	0,6780	0,3245	Desempeño insuficiente para uso estable.

Tabla 6. Resultados del stress test de disponibilidad de score_externo.

El stress test ocultó de forma aleatoria valores adicionales de score_externo sin reentrenar el modelo. La caída progresiva de AUC y F1 confirma que la cobertura de esta variable debe monitorearse como un indicador operativo de salud del sistema. Un cambio material en su disponibilidad debe activar revisión antes de continuar utilizando las predicciones.

6. Interpretabilidad: qué está usando SOLARIS

La interpretabilidad global se evaluó con SHAP sobre el pipeline final. Las tres variables originales con mayor mean(|SHAP|) son score_externo = 1,2727, ingreso_mensual = 0,2979 y edad = 0,1589. La distancia entre la primera y las demás confirma una concentración importante de señal en score_externo.

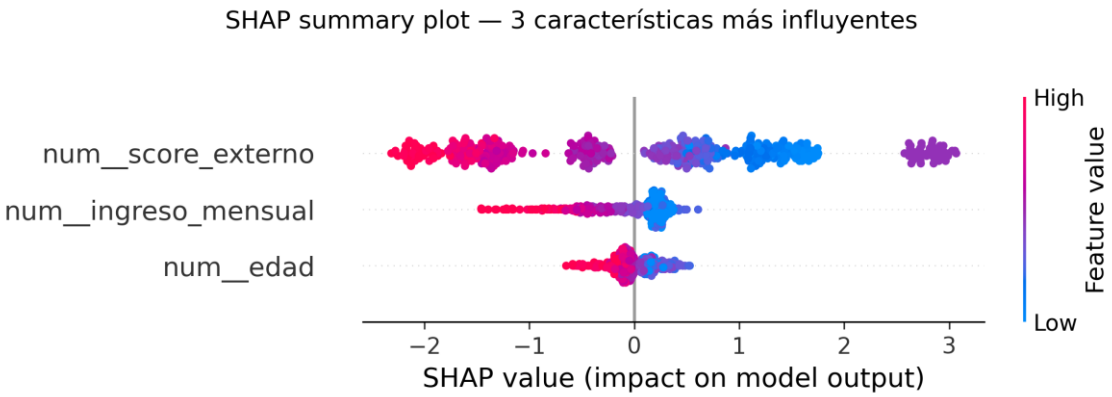


Figura 4. SHAP summary plot con las tres variables originales más influyentes.

6.1 Explicación de un caso individual

Caso auditado: índice 7136

Clase real: Moroso

Probabilidad estimada: 90,6%

Threshold: 0,59

Hallazgo: el mayor impulso hacia la predicción proviene de score_externo, que está ausente en el registro.

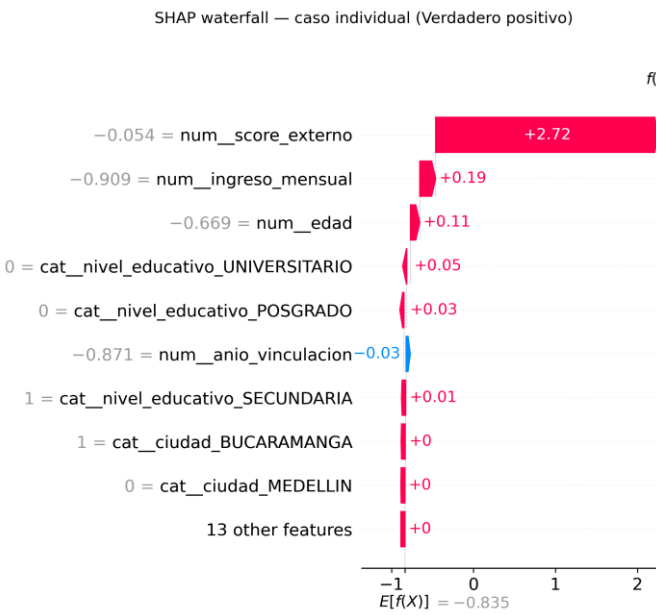


Figura 5. SHAP waterfall del verdadero positivo auditado.

SHAP describe cómo las variables empujan la salida del modelo respecto a un valor base; no demuestra relaciones causales. En este caso concreto, la explicación refuerza el hallazgo de robustez: el patrón de ausencia de score_externo está siendo utilizado como señal fuerte y no debe convertirse automáticamente en una consecuencia crediticia.

7. Equidad, sesgos y riesgos de uso

La evaluación por subgrupos incluyó nivel educativo, ciudad, edad, ingreso, antigüedad y disponibilidad de score_externo. Como métrica principal se utilizó Equal Opportunity Difference (EOD), definida como la diferencia entre el mayor y el menor recall/TPR entre grupos elegibles. Estas diferencias describen comportamiento desigual del modelo, pero no constituyen por sí solas evidencia causal de discriminación.

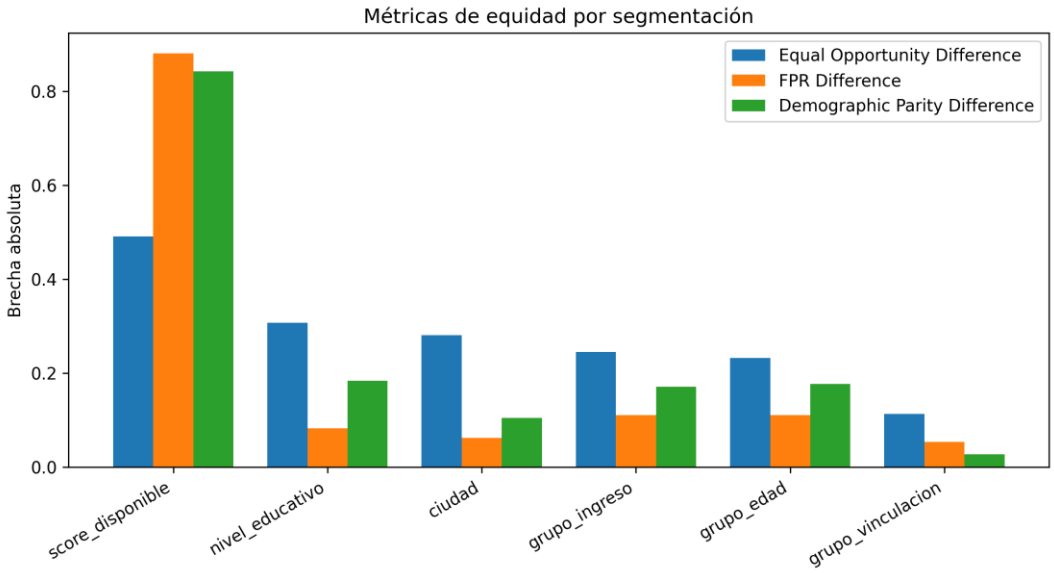


Figura 6. Brechas de Equal Opportunity Difference por segmentación.

Segmentación	EOD	Hallazgo
Disponibilidad de score	0,4908	Mayor brecha; asociada al mecanismo de datos faltantes.
Nivel educativo	0,3071	Diferencias de recall entre grupos elegibles.
Ciudad	0,2805	Cúcuta presenta mayor recall y Medellín el menor.
Ingreso	0,2451	Diferencias entre bandas de ingreso.
Edad	0,2319	Recall menor en grupos de mayor edad.
Antigüedad	0,1127	Brecha menor, pero requiere monitoreo.

Tabla 7. Principales brechas de oportunidad igual.

El caso más crítico corresponde a score_externo. Entre 2.248 clientes con score disponible, el recall es 0,5092 y el FPR 0,1197; entre 212 casos con score faltante, la tasa de alerta, el recall y el FPR son 1,0000. La ausencia del dato puede reflejar un proceso operativo o un proxy no documentado y, por tanto, debe activar una ruta separada de revisión humana.

También deben vigilarse los 313 falsos positivos del test: una política automática podría generar revisiones o restricciones injustificadas sobre clientes que realmente están al día. La responsabilidad final debe permanecer en una persona con capacidad de justificar y revertir la decisión.

8. Dashboard ejecutivo y aplicación operativa

El Módulo 5 traduce la evidencia técnica en una herramienta ejecutiva desarrollada en Streamlit. El dashboard utiliza los 2.460 registros del conjunto de prueba para una evaluación histórica y permite explorar segmentos y escenarios sin modificar el modelo oficial. Su propósito es apoyar la revisión, no reemplazarla.

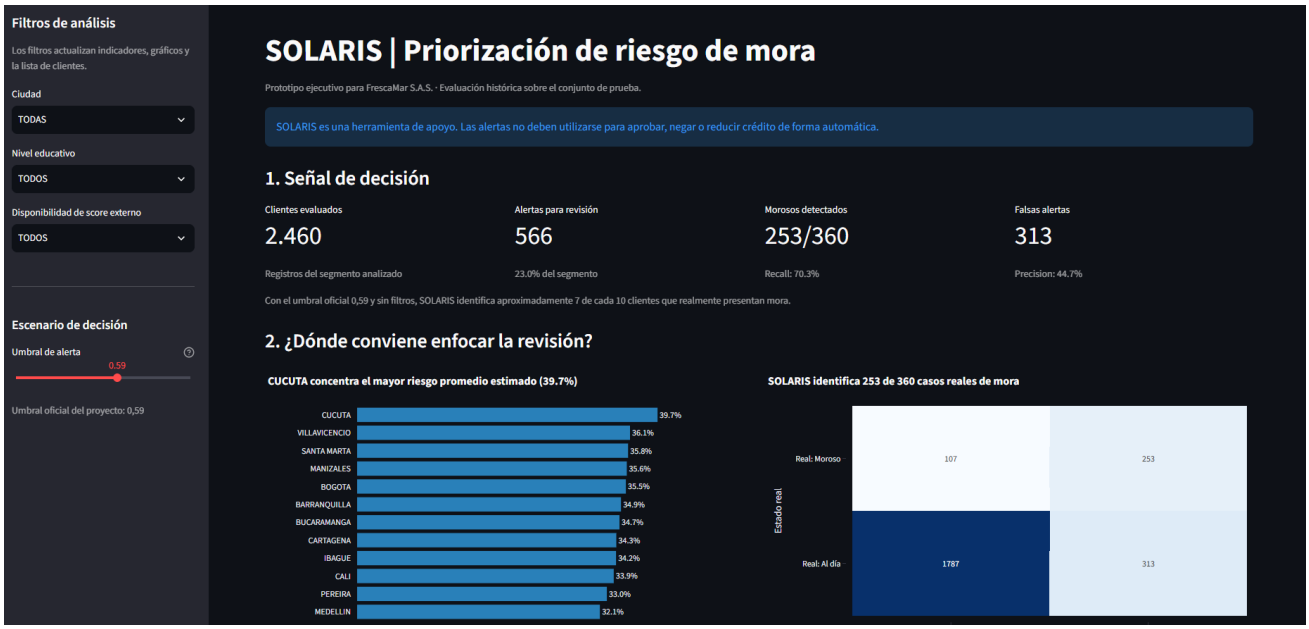


Figura 7. Vista principal del dashboard SOLARIS con el threshold oficial 0,59.

Capa	Contenido	Pregunta que responde
1. Señal de decisión	Clientes evaluados, alertas, morosos detectados y falsas alertas.	¿Qué tan grande es la carga de revisión y cuánto riesgo captura?
2. Contexto	Riesgo promedio por ciudad y matriz predicción-realidad.	¿Dónde conviene enfocar el análisis?
3. Interpretación	SHAP global, disponibilidad de score y caso individual.	¿Por qué debe interpretarse la alerta con cautela?
4. Acción	Tabla priorizada y descarga CSV.	¿Qué clientes deben revisarse primero?

Tabla 8. Jerarquía de información del dashboard.

Los filtros por ciudad, nivel educativo y disponibilidad de score actualizan indicadores, gráficos y clientes priorizados. El slider de threshold permite análisis de escenarios, pero el dashboard advierte cuando se abandona el valor oficial 0,59. La interfaz también incorpora el mensaje de que ninguna alerta debe usarse por sí sola para aprobar, negar o reducir crédito.

Como control de reproducibilidad, el repositorio documenta la generación del dataset del dashboard, las dependencias y el comando de ejecución. La solución fue probada desde un clon limpio y reprodujo las métricas oficiales antes de abrir la aplicación.

9. Impacto, gobernanza y hoja de ruta

El valor esperado de SOLARIS está en concentrar recursos de evaluación y gestión de cartera en clientes con mayor riesgo, reducir decisiones basadas únicamente en criterio informal y crear trazabilidad sobre el proceso. Sin embargo, las metas de negocio planteadas en el DDP - reducir cartera que entra en mora, disminuir ampliaciones a clientes que se deterioran y reducir tiempo de evaluación manual - continúan siendo objetivos de un piloto, no impactos ya demostrados.

Prioridad	Medida de gobernanza	Indicador
Alta	Auditar origen, cobertura y causa de ausencia de score_externo; prohibir decisiones adversas basadas solo en el faltante.	Cobertura, tasa de alerta, EOD, FPR y FNR por disponibilidad.
Alta	Mantener revisión humana obligatoria, motivo documentado y política de excepciones.	% decisiones revisadas, excepciones y reversión de alertas.
Alta	Construir snapshots con fecha_corte y fecha_evento y ejecutar validación out-of-time.	AUC, calibración y estabilidad temporal.
Media	Monitorear mensualmente desempeño y equidad por subgrupo con tamaños mínimos de muestra.	Recall, FPR, FNR, EOD y tasa de alerta.
Media	Conservar versión de datos, modelo, threshold y explicación SHAP para cada ciclo.	Trazabilidad completa de cada decisión.

Tabla 9. Controles prioritarios antes de un despliegue productivo.

9.1 Hoja de ruta recomendada

Fase	Objetivo	Criterio para avanzar
1. Piloto controlado	Usar SOLARIS solo para priorizar revisión, con decisión humana final.	Registrar decisiones, excepciones, falsos positivos y falsos negativos.
2. Calidad de datos	Estabilizar cobertura de score_externo y reglas semánticas.	Cobertura documentada y ausencia de alertas extremas por faltantes.
3. Validación temporal	Probar el modelo sobre períodos posteriores no vistos.	Desempeño y calibración aceptables en out-of-time.
4. Monitoreo	Formalizar métricas de drift, equidad y desempeño.	Umbrales de alerta y responsables definidos.
5. Producción condicionada	Integrar el score en el proceso de crédito como apoyo.	Gobernanza, trazabilidad, seguridad y revisión humana aprobadas.

Tabla 10. Hoja de ruta desde prototipo hasta una posible adopción productiva.

SOLARIS se relaciona con el ODS 9 - Industria, Innovación e Infraestructura - al proponer una capacidad analítica reproducible para decisiones financieras. Esta contribución solo es sostenible si combina innovación con calidad de datos, explicabilidad, protección de información, monitoreo de equidad y supervisión humana.

10. Conclusiones y limitaciones

SOLARIS demuestra que es posible construir una señal predictiva útil de riesgo de mora con el dataset disponible sin recurrir a variables cuya temporalidad sea dudosa. El HistGradientBoostingClassifier optimizado supera claramente la línea base y presenta AUC CV = 0,8692, AUC test = 0,8681 y gap Train-Test = 0,0254. Con threshold 0,59, identifica aproximadamente 7 de cada 10 morosos del test.

La evaluación también muestra por qué el desempeño agregado no es suficiente para justificar automatización. score_externo domina las explicaciones, la ausencia de esta variable produce un comportamiento extremo y existen brechas de desempeño por educación, ciudad, ingreso y edad. Además, 313 clientes Al día fueron clasificados como alerta. La recomendación responsable es mantener SOLARIS como herramienta de apoyo dentro de un piloto controlado.

10.1 Limitaciones principales

- No existe fecha_corte/fecha_evento ni validación out-of-time; la estabilidad temporal todavía no está demostrada.
- La ausencia de score_externo no es aleatoria y puede actuar como señal adversa no deseada.
- Las brechas por subgrupo son descriptivas y no demuestran discriminación causal.
- Las métricas de impacto financiero del DDP son objetivos para un piloto; no se presentan como beneficios realizados.
- La calibración debe evaluarse con datos temporales antes de utilizar probabilidades para reglas de cupo.

10.2 Recomendación final

Avanzar únicamente con un piloto controlado y supervisado. No utilizar SOLARIS para aprobar, negar o reducir crédito de forma autónoma; no tomar decisiones adversas basadas únicamente en la ausencia de score_externo; mantener trazabilidad de datos, modelo y threshold; monitorear desempeño y equidad; y exigir validación temporal antes de producción.

Referencias

[1] Torres Castellanos, N. (2026). Documento de Definición del Proyecto (DDP) - Proyecto SOLARIS, Módulo 1.

[2] Torres Castellanos, N. (2026). Plan del pipeline analítico y optimización del modelo - Proyecto SOLARIS, Módulo 2.

[3] Torres Castellanos, N. (2026). M3_PCD2_TorresCastellanos_Prototipo.ipynb. Proyecto SOLARIS, FrescaMar S.A.S.

[4] Torres Castellanos, N. (2026). Informe de validación técnica y análisis de sesgos - Proyecto SOLARIS, Módulo 4.

[5] Torres Castellanos, N. (2026). Análisis de impacto social, económico y ético - Proyecto SOLARIS, Módulo 4.

[6] Congreso de Colombia. (2012). Ley 1581 de 2012 - Protección de datos personales.

[7] UNESCO. (2021). Recomendación sobre la Ética de la Inteligencia Artificial.

[8] Tuto Chévere. (2026). Guía de actividad - Unidad 5. Proyecto Ciencia de Datos 2.

[9] Universidad de La Sabana. (2026). Guía de actividad - Unidad 5. Proyecto de Ciencia de Datos 2.

Repositorio y reproducibilidad

Repositorio público: https://github.com/torresnicolas004-afk/SOLARIS-FrescaMar

Autor: Nicolás Torres Castellanos | Universidad de La Sabana | Proyecto de Ciencia de Datos 2 | 2026-2