SOLARIS

Priorización de riesgo de mora para FrescaMar S.A.S.

De un problema de cartera a una herramienta explicable de apoyo a la decisión

AUC test 0,8681 | Recall 70,3% | Piloto controlado

Nicolás Torres Castellanos

Proyecto de Ciencia de Datos 2 · Universidad de La Sabana · 2026-2

DATA DAY · Presentación final

FrescaMar necesita anticipar la mora antes de ampliar exposición

El problema no es describir quién está en mora hoy, sino priorizar a quién revisar antes de que el riesgo se materialice.

REGISTROS AUDITADOS
15.000
11 variables · 15.000 IDs únicos

MOROSOS OBSERVADOS
1.800
12% del dataset original

SALDO PROMEDIO MOROSO
2,79×
vs. clientes Al día

DECISIÓN OBJETIVO
Revisar
antes de aprobar, mantener o ampliar cupo

Problema de negocio: FrescaMar no dispone de una estimación anticipada, consistente y explicable del riesgo de mora por cliente.

La salida del proyecto debe orientar al Director Financiero y al equipo de crédito/cartera. No reemplaza el criterio humano.

La exposición observada en cartera es evidencia del problema, no una pérdida realizada.

Fuente: DDP Módulo 1 y alcance final del Proyecto SOLARIS.

SOLARIS convierte un snapshot de cartera en una señal de revisión

La solución prioriza clientes por probabilidad estimada de mora y conserva supervisión humana en la decisión final.

1. Datos de entrada

- Perfil del cliente
- Ingreso y antigüedad
- Score externo
- Ciudad y educación

2. Pipeline analítico

- Limpieza + imputación
- One-hot categórico
- HistGradientBoosting
- Optuna + CV estratificada

3. Consumo

- Probabilidad de mora
- Alerta con threshold 0,59
- Explicación SHAP
- Lista priorizada para revisión

Resultado: una herramienta para decidir qué revisar primero, no para decidir automáticamente quién recibe crédito.

Arquitectura final integrada a partir del DDP, M3 y M4.

La mayor decisión metodológica fue evitar leakage

El modelo final usa solo información defendible antes de la decisión y excluye variables contemporáneas al estado de cartera.

SE USA EN EL MODELO

✓ **edad**	perfil
✓ **ingreso_mensual**	capacidad económica
✓ **anio_vinculacion**	antigüedad
✓ **score_externo**	riesgo externo
✓ **nivel_educativo**	perfil categórico
✓ **ciudad**	ubicación

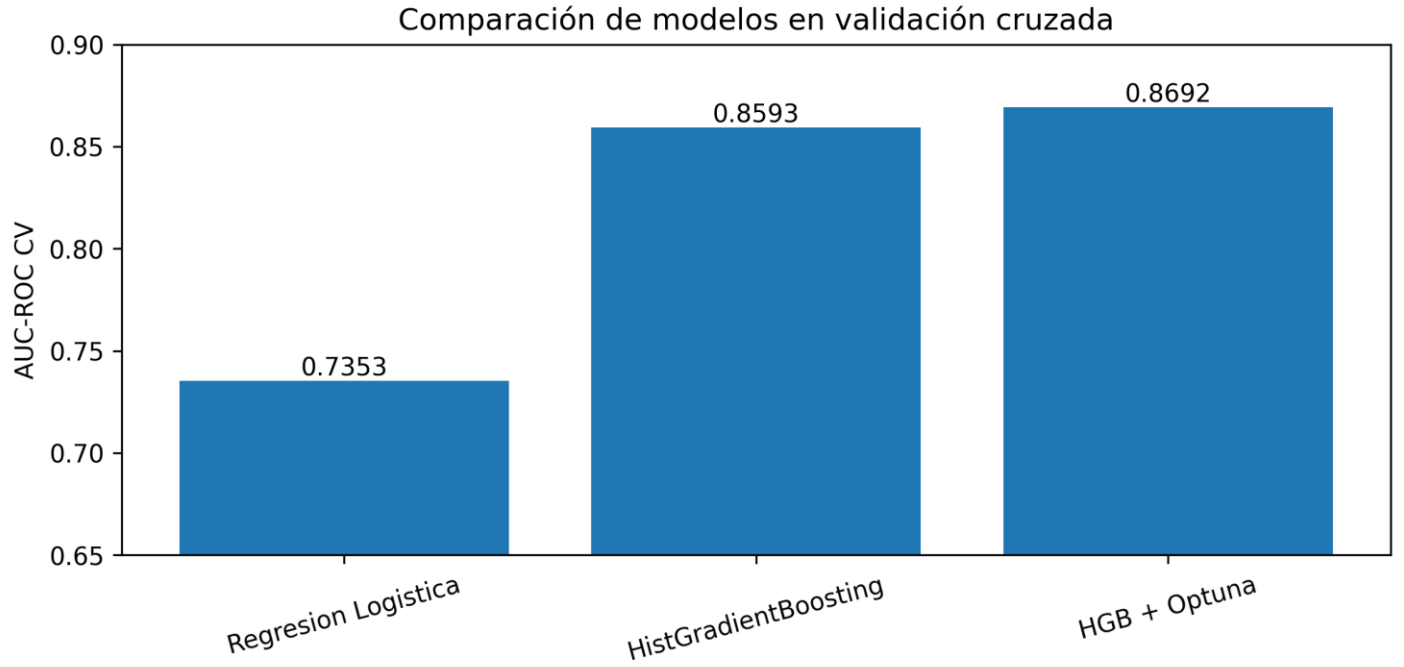
SE EXCLUYE DEL MODELO

✗ **id_cliente**	identificador
✗ **saldo_actual**	riesgo de temporalidad/leakage
✗ **cuotas_pagadas**	información potencialmente posterior
✗ **cuotas_totales**	estructura del crédito actual
✗ **estado_cuenta**	es la variable objetivo

12.300 registros de modelado · **Moroso = 1 · Al día = 0** · **Cancelado excluido** · **Split 80/20 · semilla 42** · **Test = 2.460**

El modelo se seleccionó por evidencia, no por preferencia

HGB + Optuna fue superior al baseline interpretable y al HGB sin optimizar en validación cruzada estratificada.



AUC CV HGB + OPTUNA

0,8692

5 folds estratificados

AUC CV BASELINE

0,7353

Regresión Logística

OPTIMIZACIÓN

50 trials

Optuna sobre train

Mejora de AUC ≈ +0,134 frente al baseline.

M3/M4: comparación de modelos mediante validación cruzada; el test no se usa para elegir el algoritmo.

El modelo generaliza bien en el test aislado

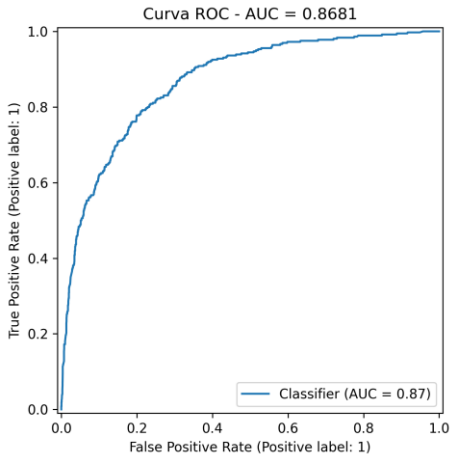
El desempeño de test se mantiene cercano a train y supera los objetivos técnicos definidos al inicio del proyecto.

AUC TEST
0,8681
capacidad de ranking

RECALL MOROSO
70,3%
253 de 360 morosos

PRECISION
44,7%
calidad de la alerta

GAP TRAIN–TEST
0,0254
sin evidencia fuerte de sobreajuste



Curva ROC sobre test

El test quedó aislado hasta el final. El threshold también se definió con predicciones OOF de train.

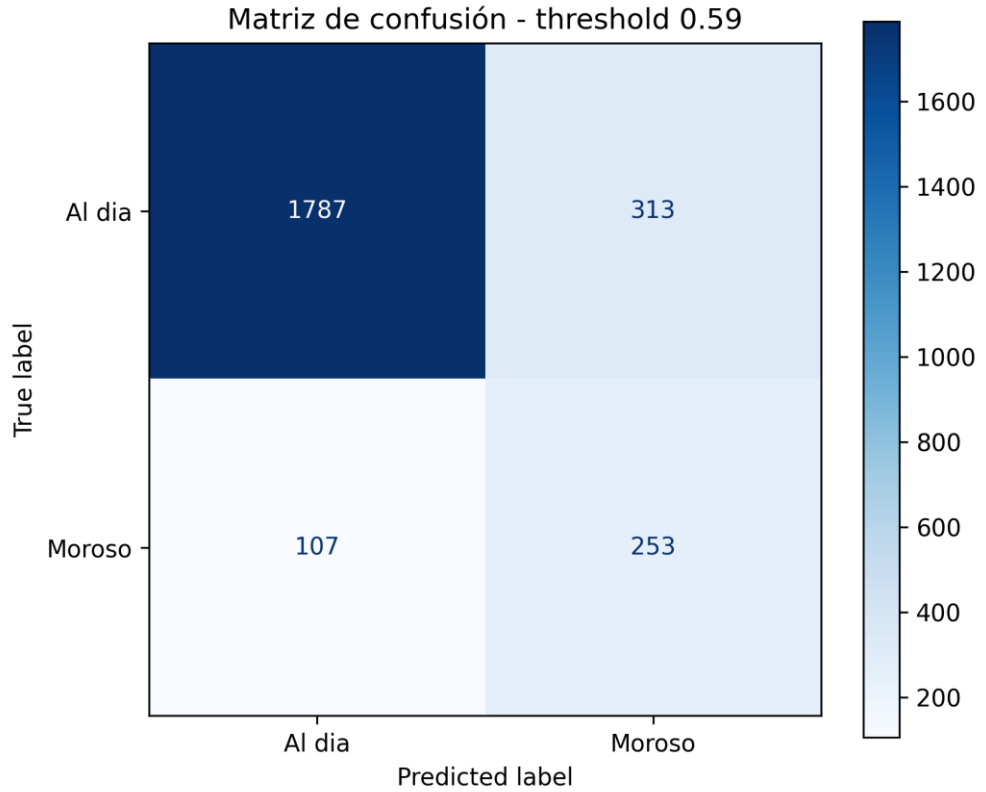
Objetivos del DDP

- AUC ≥ 0,75 → CUMPLIDO
- Recall ≥ 70% → CUMPLIDO
- Precision ≥ 40% → CUMPLIDO

M4 Actividad 1: validación técnica del modelo final.

Con threshold 0,59 se detectan 253 de 360 morosos

La cobertura es útil para priorizar revisiones, pero 313 falsas alertas hacen inadecuada una decisión crediticia automática.



VERDADEROS +

253

morosos detectados

FALSOS -

107

morosos no detectados

FALSOS +

313

clientes Al día alertados

VERDADEROS -

1.787

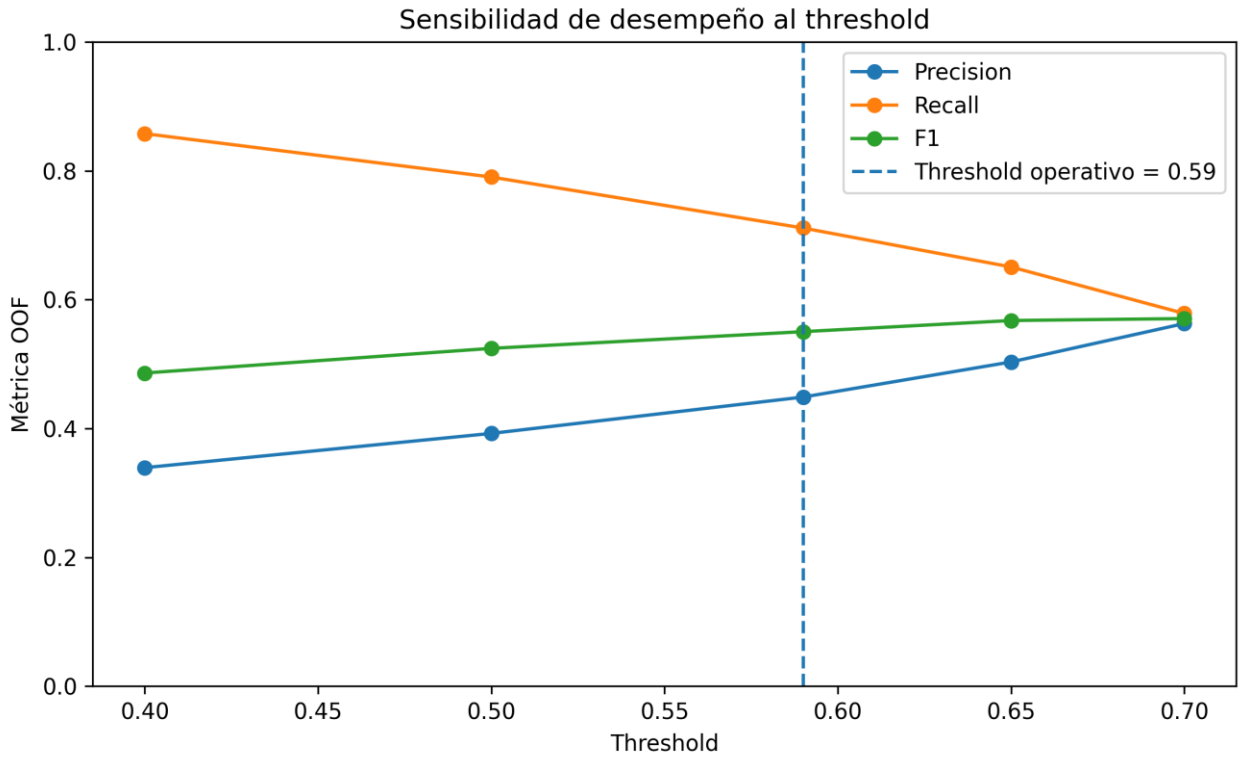
clientes Al día sin alerta

Lectura ejecutiva: SOLARIS detecta aproximadamente 7 de cada 10 casos reales de mora.

Uso recomendado: priorizar revisión humana.

El threshold 0,59 equilibra cobertura y calidad de alerta

Mover el punto de corte cambia de forma importante quién queda priorizado y qué costo operativo asume FrescaMar.



0,40
Recall 85,8% · Precision 33,9%

0,59 — OFICIAL
Recall 71,1% · Precision 44,9%
(OOF)

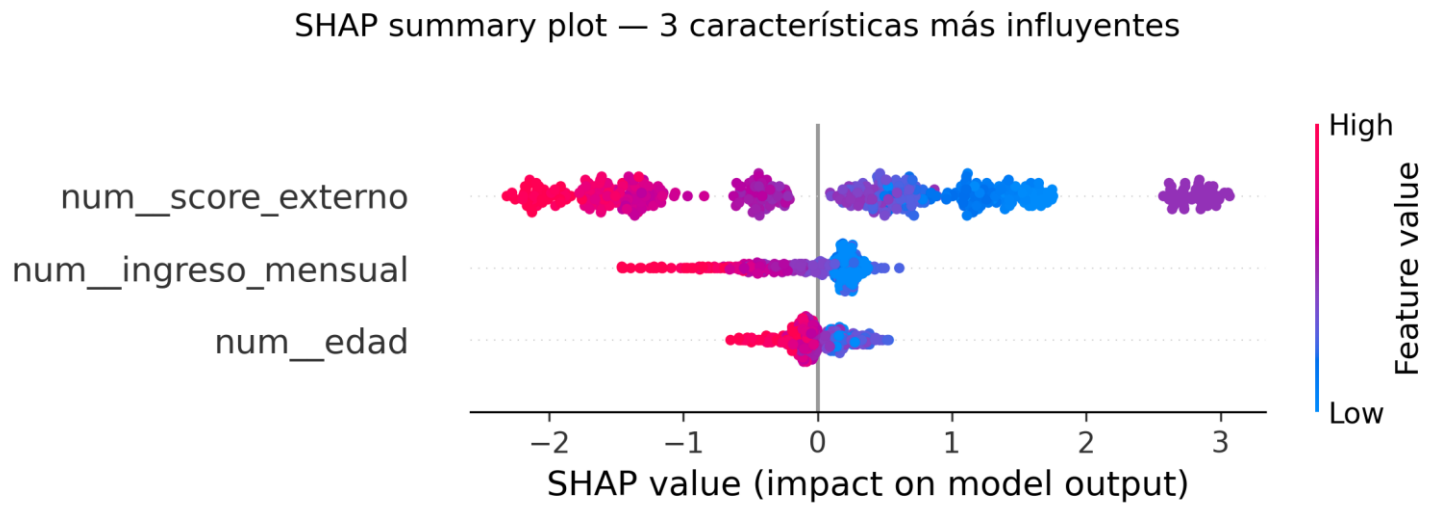
0,70
Recall 57,9% · Precision 56,3%

El threshold oficial se congeló antes de mirar el desempeño final de test.

Sensibilidad OOF de train; el test no se usa para reajustar el punto de corte.

score_externo es la principal señal predictiva

SHAP muestra qué variables mueven las predicciones del modelo; describe comportamiento del modelo, no causalidad.



La concentración de señal en score_externo conecta directamente con el principal riesgo de robustez y equidad.

score_externo

1,2727

mean(|SHAP|)

ingreso_mensual

0,2979

mean(|SHAP|)

edad

0,1589

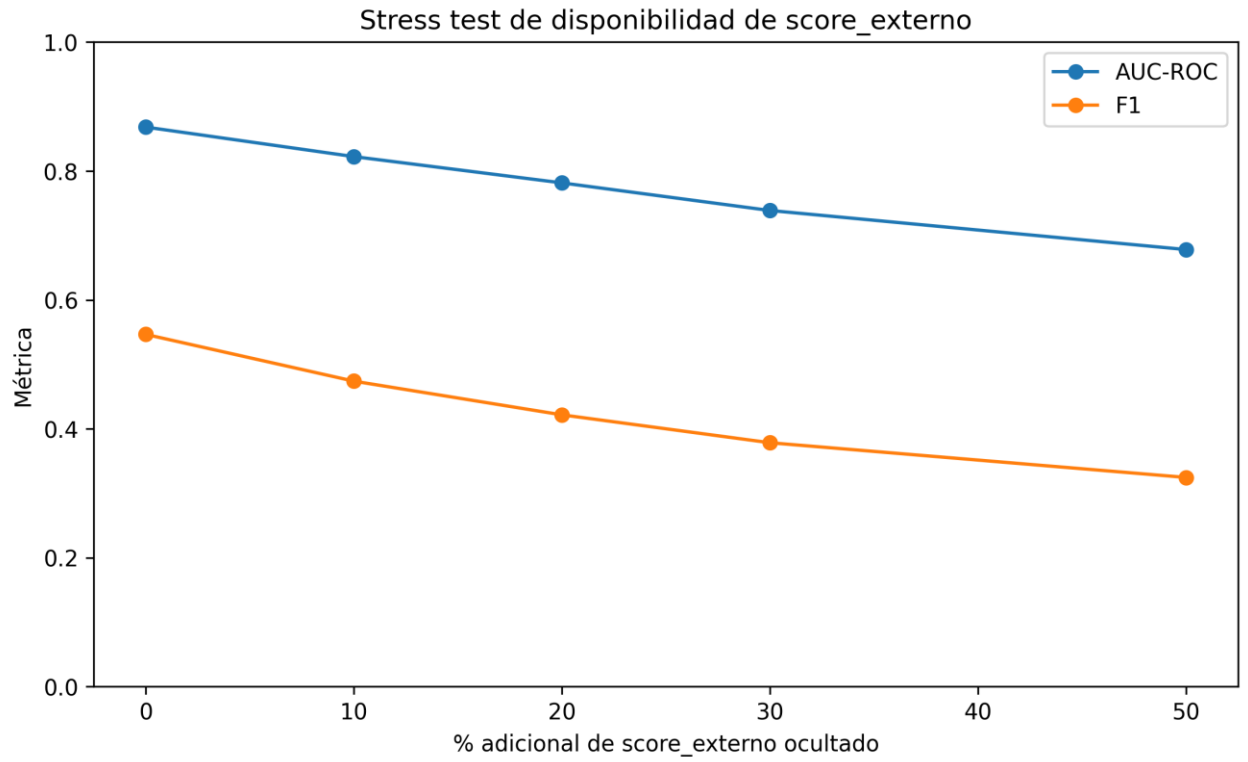
mean(|SHAP|)

M4: interpretación global SHAP sobre el pipeline final.

PROYECTO SOLARIS

El modelo pierde robustez cuando aumenta la ausencia de score_externo

La calidad de este dato debe convertirse en un control operativo antes de cualquier uso productivo.



SIN FALTANTE EXTRA

AUC 0,868

F1 0,546

+30% FALTANTES

AUC 0,739

F1 ≈ 0,378

+50% FALTANTES

AUC 0,678

F1 0,324

Control recomendado: monitorear cobertura de score_externo.

Stress test M4: ocultamiento adicional de score_externo sin reentrenar el modelo.

Los 212 casos sin score requieren una ruta de revisión separada

El patrón de faltantes no puede convertirse en una razón automática para restringir crédito.

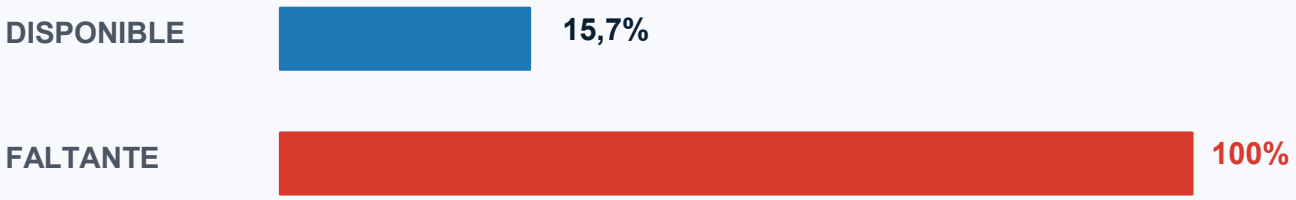
SCORE DISPONIBLE
2.248
clientes de test

SCORE FALTANTE
212
clientes de test

TASA DE ALERTA
100%
en el subgrupo faltante

EOD
0,4908
mayor brecha observada

Tasa de alerta por disponibilidad de score



Regla de gobernanza

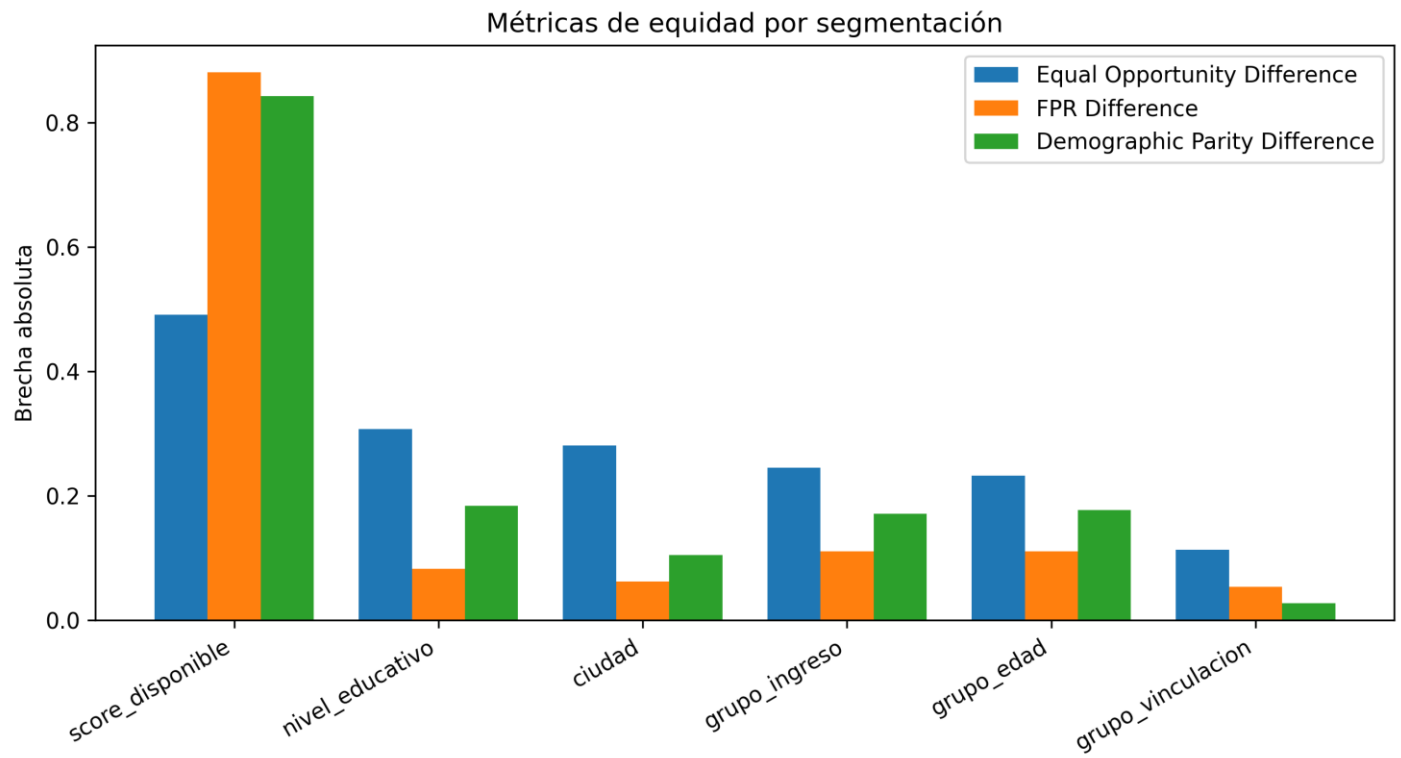
- Revisión humana obligatoria
- No usar el faltante como evidencia de mora
- Auditar origen y cobertura del score

Este hallazgo es el principal límite para una implementación autónoma.

M4: score faltante n=212; recall=1,00 y FPR=1,00 en ese subgrupo.

La equidad debe monitorearse por varios subgrupos

Las brechas son señales descriptivas de desempeño desigual; no constituyen por sí solas evidencia causal de discriminación.



NIVEL EDUCATIVO

EOD 0,307

brecha relevante

CIUDAD

EOD 0,281

brecha relevante

INGRESO / EDAD

0,245 / 0,232

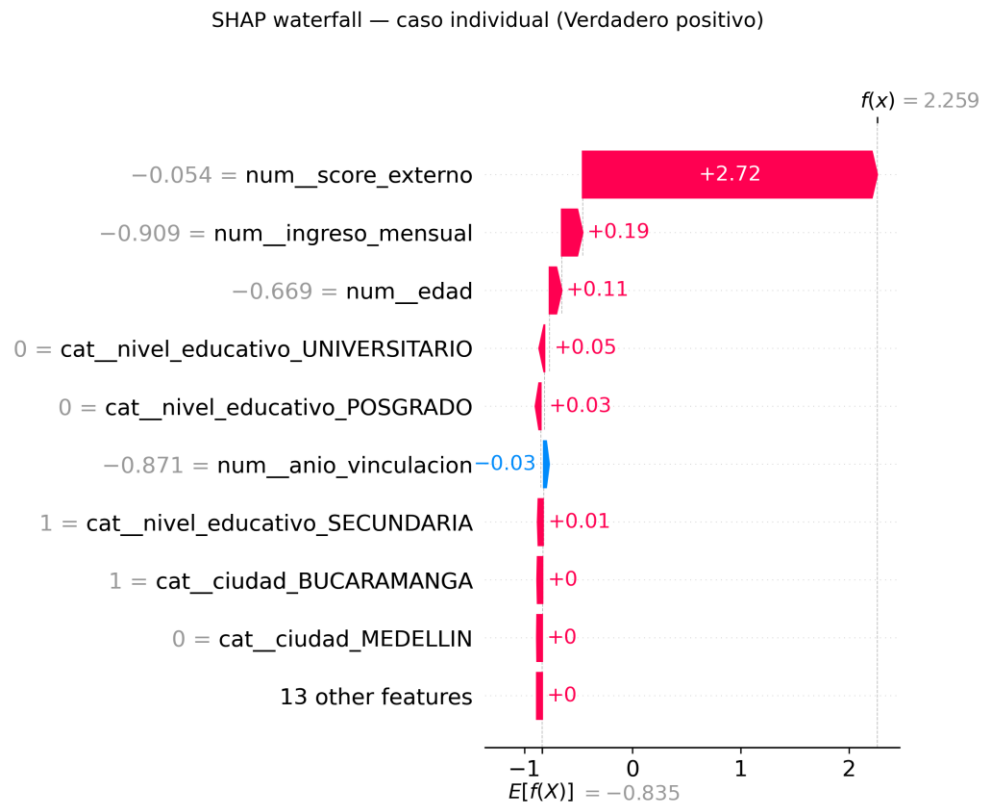
monitoreo requerido

Medir mensualmente EOD, FPR, FNR y recall por subgrupo.

No se dispone de variables de sexo, raza o etnia en el dataset.

Un caso individual muestra cómo el score faltante impulsa la alerta

Caso auditado: verdadero positivo con probabilidad estimada de mora de 90,6%.



PROBABILIDAD

90,6%

threshold 0,59

CLASE REAL

MOROSO

verdadero positivo

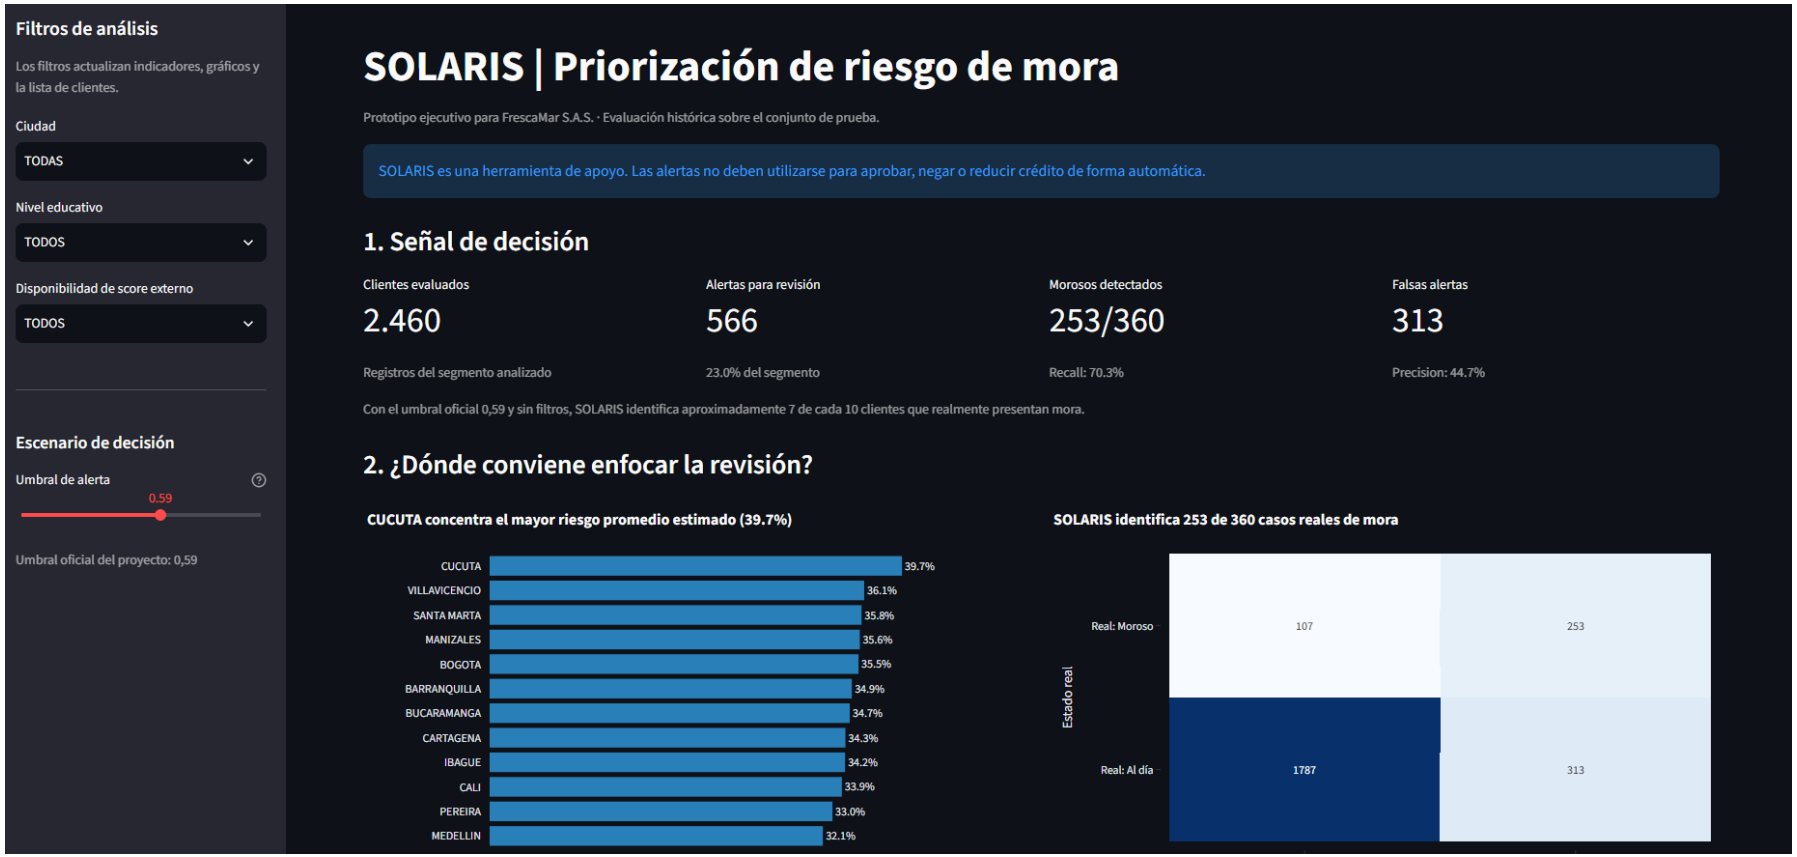
Mayor impulso hacia riesgo: score_externo ausente

SHAP explica esta predicción concreta. No demuestra que la ausencia del score cause mora.

Caso M4, índice 7136 del conjunto de prueba.

El dashboard convierte el modelo en una herramienta operativa

La interfaz traduce métricas, riesgo y explicaciones en una experiencia de revisión para negocio.



DEMO

- Filtros por ciudad y educación
- Threshold interactivo
- KPIs y matriz de confusión
- SHAP global + caso individual
- Clientes priorizados descargables

Uso: apoyar revisión, no automatizar crédito.

Dashboard Streamlit final; vista histórica sobre el conjunto de prueba.

El proyecto es reproducible y auditable desde un clon limpio

La entrega final incluye código, modelo congelado, dependencias versionadas, artefactos y dashboard documentado.



Clonar	Instalar	Regenerar	Validar	Ejecutar
Repositorio público en GitHub	Python 3.13 + requirements.txt	2.460 predicciones de test	Matriz oficial 1787 / 313 / 107 / 253	Dashboard Streamlit

Prueba realizada: instalación solo desde requirements.txt → generación de predicciones → validación automática → dashboard sin errores.

github.com/torresnicolas004-afk/SOLARIS-FrescaMar

El repositorio mantiene historial de commits y artefactos separados por módulo.

La recomendación es un piloto controlado, no automatización

SOLARIS tiene señal predictiva útil, pero su adopción depende de gobernanza, calidad de datos y validación temporal.

SÍ HACER

- Piloto con revisión humana obligatoria
- Ruta especial para score_externo faltante
- Monitoreo mensual de desempeño y equidad
- Trazabilidad de modelo, threshold y responsable
- Validación out-of-time antes de producción

NO HACER

- Aprobar, negar o reducir crédito automáticamente
- Tomar una decisión adversa solo porque falta el score
- Aplicar el modelo a otro período o población sin validar
- Cambiar el threshold usando el conjunto de test
- Prometer impacto financiero antes de un piloto real

Próximo hito: construir snapshots con fecha_corte/fecha_evento y ejecutar validación out-of-time.

SOLARIS aporta valor si se usa con control

La evidencia final combina desempeño, explicabilidad, robustez, equidad y una forma responsable de llevar el modelo a negocio.

AUC test 0,8681 | **Recall 70,3%** | **253 / 360 morosos** | **Threshold 0,59**

1 Detectar mejor

Priorización del riesgo con evidencia cuantitativa.

2 Entender la alerta

SHAP + robustez + equidad para interpretar límites.

3 Decidir con supervisión

Piloto controlado, revisión humana y monitoreo.

Gracias · Preguntas

github.com/torresnicolas004-afk/SOLARIS-FrescaMar

Nicolás Torres Castellanos · Universidad de La Sabana · 2026-2

Fuentes del proyecto: DDP M1 · Prototipo M3 · Validación/Impacto M4 · Dashboard M5