INFORME DE VALIDACIÓN TÉCNICA
Y ANÁLISIS DE SESGOS

Proyecto SOLARIS

FrescaMar S.A.S.

Fecha	03/10/2026
Versión	v4.3
Autor	Nicolás Torres Castellanos
Curso	Proyecto de Ciencia de Datos 2
Período académico	2026-2
Estado del documento	Actividad 1 realizada con validación, SHAP y equidad

Contenido

1. Alcance y metodología 3
2. Validación técnica del modelo 3
2.1 Desempeño final en test y generalización 4
2.2 Sensibilidad al threshold 4
3. Robustez e interpretabilidad 5
3.1 Stress test de score_externo 5
3.2 Interpretabilidad global con SHAP 5
3.3 Interpretabilidad local 6
4. Identificación y análisis de sesgos 7
5. Propuestas de mejora y sostenibilidad 8
5.1 Condiciones de uso 8
6. Conclusiones 8
Referencias 8

1. Alcance y metodología

En esta actividad evalúa la robustez, generalización e imparcialidad del prototipo SOLARIS sin modificar el modelo final seleccionado en el Módulo 3. Se mantiene el problema Moroso = 1 frente a Al día = 0, con 12.300 registros de modelado, split 80/20 estratificado, semilla 42 y seis predictores: edad, ingreso mensual, anio_vinculacion, score_externo, nivel educativo y ciudad. La auditoría integra métricas de test, validación cruzada, comparación con línea base, sensibilidad al threshold, stress test de datos faltantes, interpretabilidad SHAP y análisis de equidad por subgrupos.

2. Validación técnica del modelo

El HistGradientBoostingClassifier optimizado con Optuna fue evaluado mediante validación cruzada estratificada de cinco folds sobre train. El AUC-ROC medio fue 0,8692, frente a 0,7353 de la Regresión Logística y 0,8593 del HGB sin optimizar. También supera la línea base en Average Precision, precision, recall y F1. Los AUC de los cinco folds se ubican entre 0,8505 y 0,8824, por lo que no se observa dependencia de una única partición.

Métrica CV	HGB + Optuna	Regresión Logística
AUC-ROC	0,8692	0,7353
Average Precision	0,5776	0,3054
Precision	0,3926	0,2485
Recall	0,7903	0,6819
F1	0,5245	0,3643

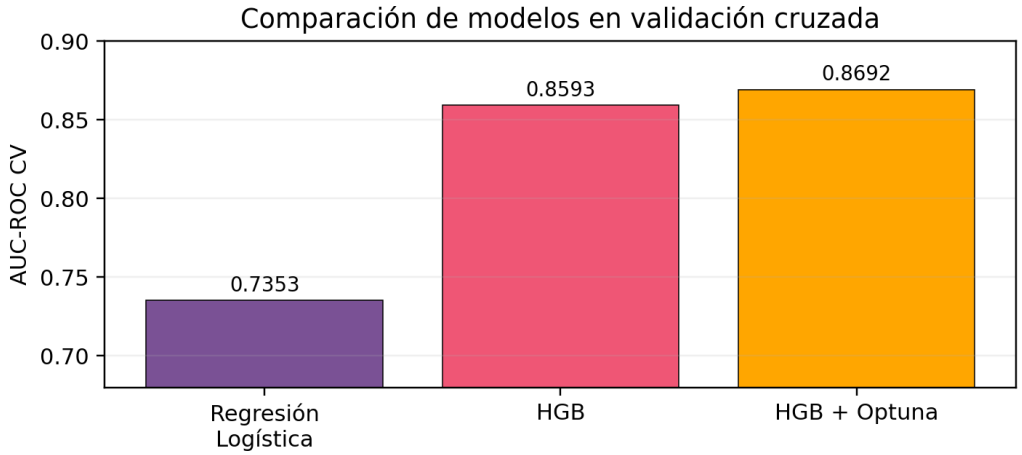


Figura 1. Comparación de modelos en validación cruzada estratificada.

2.1 Desempeño final en test y generalización

Con el threshold operativo 0,59 seleccionado exclusivamente a partir de predicciones out-of-fold de train, el conjunto de test de 2.460 casos obtiene AUC-ROC = 0,8681, precision = 0,4470, recall = 0,7028 y F1 = 0,5464 para la clase Moroso. El modelo detecta 253 de 360 morosos y genera 313 falsas alertas. El AUC de train es 0,8935 y el gap Train-Test es 0,0254, muy por debajo del control de 0,10, por lo que no existe evidencia fuerte de sobreajuste.

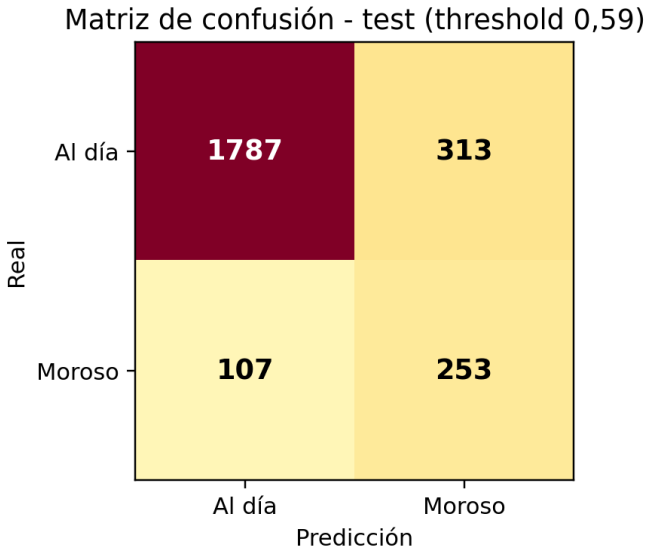


Figura 2. Matriz de confusión sobre el conjunto de prueba.

Métrica test	Resultado	Interpretación
AUC-ROC	0,8681	Buen poder de ranking de riesgo.
Precision Moroso	0,4470	44,70% de las alertas son morosos reales.
Recall Moroso	0,7028	Detecta 70,28% de los morosos.
F1 Moroso	0,5464	Equilibrio entre precision y recall.
Gap Train-Test	0,0254	Diferencia aceptable entre train y test.

2.2 Sensibilidad al threshold

El threshold representa un compromiso operativo. A 0,40 el recall aumenta a 0,8576, pero la precision cae a 0,3391; a 0,70 la precision sube a 0,5628 y el recall baja a 0,5785. El punto 0,59 conserva el criterio previo de precision mayor o igual a 0,40 y recall mayor o igual a 0,70 sin usar test para reajustar la decisión.

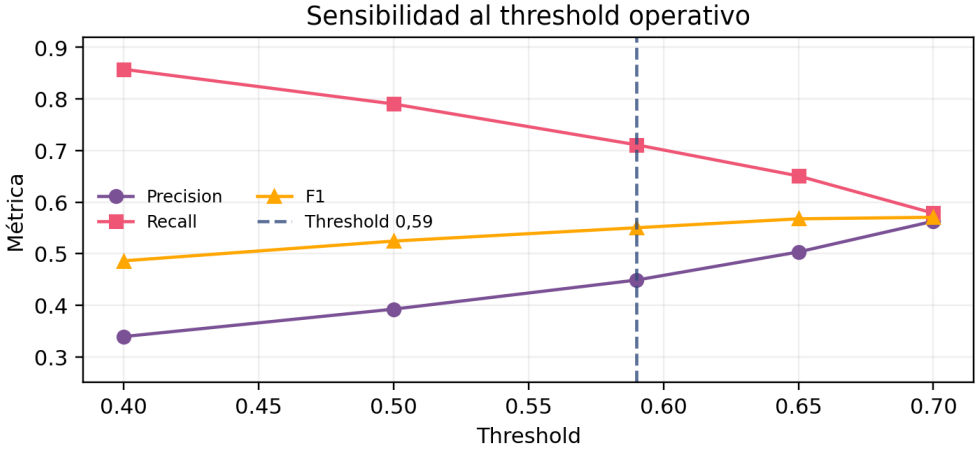


Figura 3. Sensibilidad de las métricas al threshold operativo.

3. Robustez e interpretabilidad

3.1 Stress test de score_externo

El stress test oculta aleatoriamente valores adicionales de score_externo sin reentrenar el modelo. Con 10% adicional de faltantes, el AUC cae de 0,8681 a 0,8223; con 30% llega a 0,7387 y con 50% a 0,6780. En ese último escenario el F1 disminuye de 0,5464 a 0,3245. El resultado confirma una dependencia material de la disponibilidad de este predictor y obliga a controlar su cobertura antes de cualquier uso operativo.

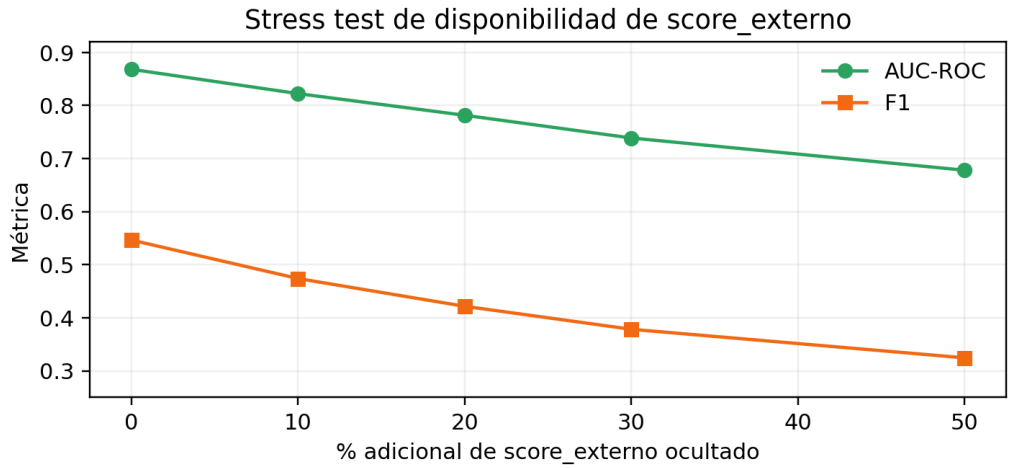


Figura 4. Robustez ante mayor ausencia de score_externo.

3.2 Interpretabilidad global con SHAP

SHAP se ejecutó correctamente sobre el pipeline final. La importancia global identifica como variables originales más influyentes score_externo, ingreso_mensual y edad. score_externo presenta mean(|SHAP|) = 1,2727, muy por encima de ingreso_mensual = 0,2979 y edad = 0,1589. La concentración de señal en score_externo coincide con el stress test y refuerza la necesidad de auditar su origen, cobertura y finalidad de uso.

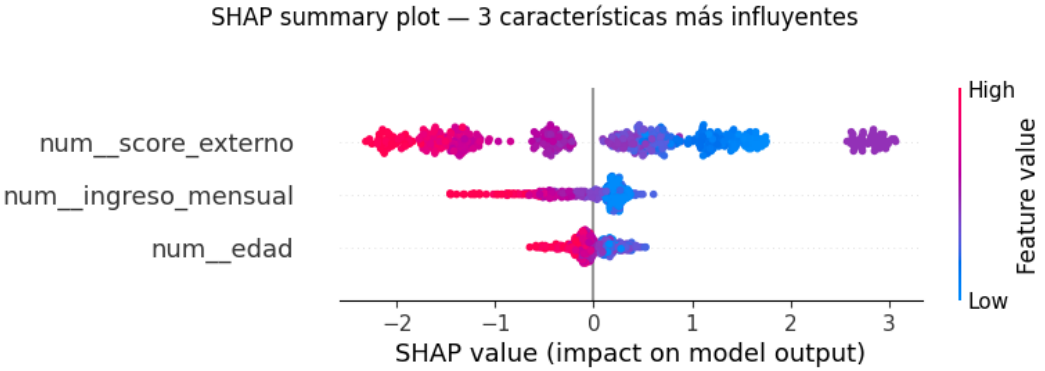


Figura 5. SHAP summary plot con las tres variables más influyentes.

3.3 Interpretabilidad local

El SHAP waterfall se generó para un verdadero positivo del test: índice 7136, clase real Moroso y probabilidad estimada de mora 0,9063 frente al threshold 0,59. El mayor impulso hacia la predicción de riesgo proviene de score_externo. En el registro original, score_externo está ausente, por lo que este ejemplo confirma que el patrón de faltantes está siendo utilizado como señal fuerte por el modelo. La explicación describe el comportamiento del modelo y no debe interpretarse como relación causal.

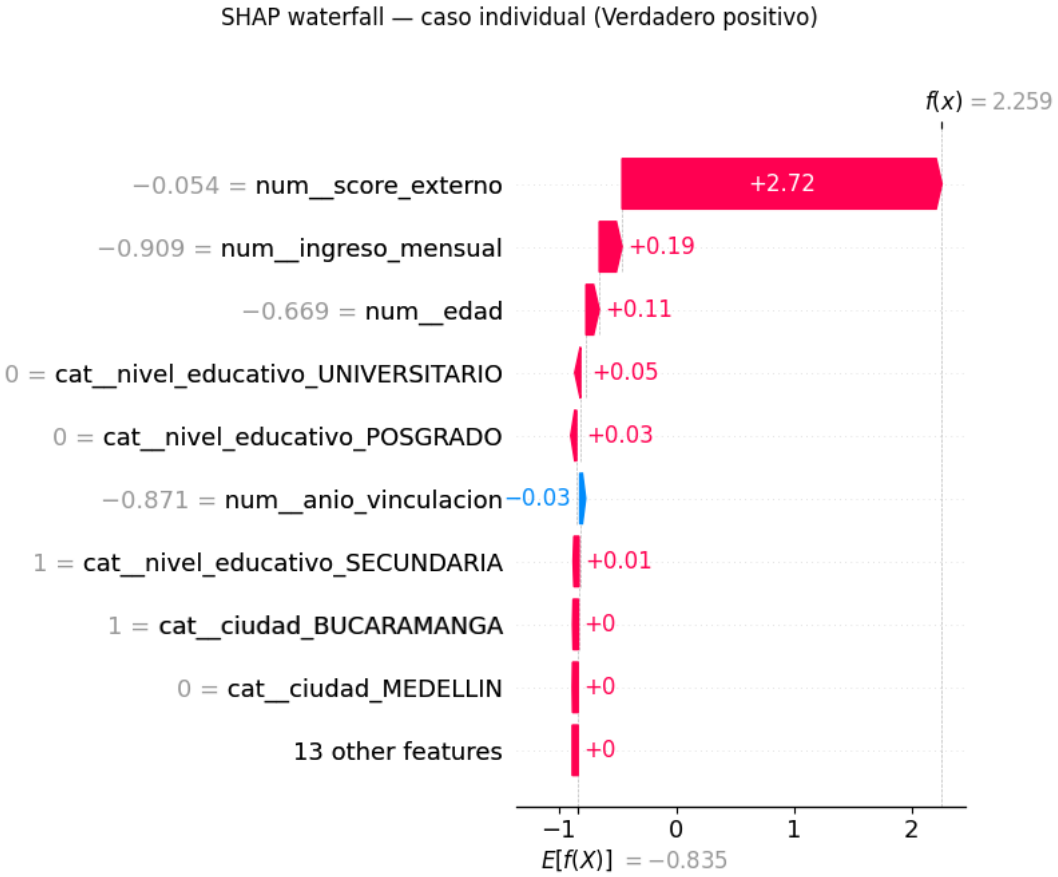


Figura 6. SHAP waterfall para un verdadero positivo del conjunto de test.

Variable original	mean(|SHAP|)	Lectura de negocio
score_externo	1,2727	Principal señal predictiva; exige control de cobertura y calidad.
ingreso_mensual	0,2979	Aproxima capacidad económica; los ceros requieren validación semántica.
edad	0,1589	Aporta señal de perfil; requiere monitoreo por grupos etarios.

4. Identificación y análisis de sesgos

El desempeño se evaluó por nivel educativo, ciudad, edad, ingreso, antigüedad y disponibilidad de score_externo. Se reportan tamaño de grupo, prevalencia, tasa de alerta, precision, recall/TPR, FPR, FNR y AUC-ROC. Como métrica formal de equidad se utiliza Equal Opportunity Difference (EOD), definida como la diferencia entre el mayor y el menor recall/TPR de los grupos elegibles. También se calcularon FPR Difference y Demographic Parity Difference. Estas métricas revelan diferencias de desempeño, pero no constituyen por sí solas evidencia causal de discriminación.

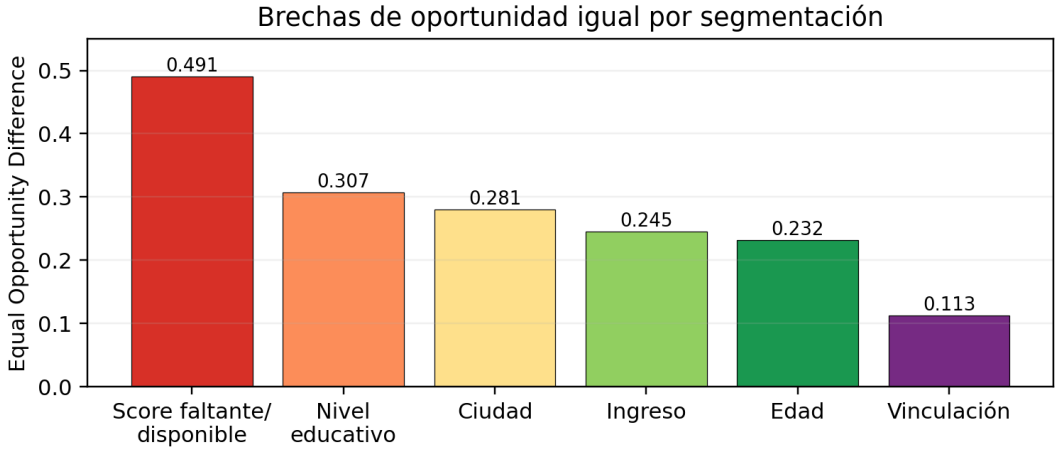


Figura 7. Equal Opportunity Difference por segmentación.

Segmentación	EOD	Hallazgo principal
Disponibilidad de score	0,4908	Mayor brecha; está asociada al mecanismo de datos faltantes.
Nivel educativo	0,3071	Recall mayor en Primaria y menor en Universitario entre grupos elegibles.
Ciudad	0,2805	Cúcuta presenta mayor recall y Medellín el menor.
Ingreso	0,2451	Se observan diferencias entre bandas de ingreso.
Edad	0,2319	El recall disminuye desde menores de 30 hasta 60+.
Vinculación	0,1127	Brecha menor, pero debe mantenerse en monitoreo.

El caso más crítico corresponde a score_externo. Entre 2.248 clientes con score disponible, el recall es 0,5092 y el FPR 0,1197; entre 212 casos con score faltante, la tasa de alerta, el recall y el FPR son 1,0000. La ausencia del dato no debe interpretarse como evidencia de mora por sí misma. Puede reflejar un proceso operativo, selección previa o un proxy no documentado, por lo que requiere una ruta de revisión separada.

5. Propuestas de mejora y sostenibilidad

Prioridad	Medida	Vinculación con el hallazgo
Alta	Auditar origen, cobertura y mecanismo de ausencia de score_externo; establecer contrato de calidad.	El faltante activa 100% de alertas y el stress test degrada AUC y F1.
Alta	Crear una ruta obligatoria de revisión humana para casos con score faltante.	Evita decisiones adversas basadas únicamente en un faltante operativo.
Alta	Construir snapshots con fecha_corte y fecha_evento y realizar validación out-of-time.	El split IID actual no demuestra estabilidad temporal.
Media	Monitorear mensualmente EOD, FPR, FNR, recall y tamaños de muestra por subgrupo.	Permite detectar aumento o cambio de brechas.
Media	Evaluar calibración y costo de falsos positivos y falsos negativos antes de modificar el threshold.	El punto de corte cambia de forma importante el impacto operativo.
Media	Conservar SHAP y métricas de robustez como parte del monitoreo de nuevas versiones.	Aumenta trazabilidad y permite detectar cambios en variables dominantes.

5.1 Condiciones de uso

- No utilizar SOLARIS para aprobar, negar o reducir crédito de forma autónoma.
- No tomar una decisión adversa basándose únicamente en la ausencia de score_externo.
- No aplicar el modelo a otra población o período sin una validación específica.
- Suspender o revisar el uso si cambia materialmente la cobertura de variables, aparecen brechas crecientes o cae el desempeño.
- Mantener trazabilidad de datos, versión del modelo, threshold y responsable de la decisión final.

6. Conclusiones

El modelo presenta desempeño sólido y estable en la validación disponible: AUC CV = 0,8692, AUC test = 0,8681 y gap Train-Test = 0,0254. La comparación con la línea base y la estabilidad entre folds respaldan la capacidad predictiva del prototipo. Sin embargo, la robustez y la equidad están condicionadas por score_externo. SHAP confirma que es la variable dominante y el análisis de subgrupos muestra que su ausencia produce la mayor brecha de oportunidad igual. También se observan diferencias relevantes por educación, ciudad, ingreso y edad. En consecuencia, SOLARIS puede continuar como herramienta de apoyo y piloto controlado, pero requiere revisión humana, monitoreo de equidad, calidad de datos y validación temporal antes de una adopción productiva.

Referencias

[1] O'Neil, C. (2016). Weapons of Math Destruction. Crown.
[2] Torres Castellanos, N. (2026). M4_PCD2_TorresCastellanos_Validacion.ipynb. Proyecto SOLARIS, FrescaMar S.A.S.
[3] Torres Castellanos, N. (2026). Plan del pipeline analítico y optimización del modelo. Proyecto SOLARIS, Módulo 2.
[4] Tuto Chévere. (2026). Guía de actividad - Unidad 4. Proyecto Ciencia de Datos 2.